



UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH

PREDICTOR GOLES DE LA LIGA ESPAÑOLA DE FÚTBOL

Aprenentatge Automàtic (APA)
Grau en Enginyeria Informàtica (UPC)

Autores:

Ana Aparicio Ortega
Ismael Pintor Carcedo

Subgrupo: 13

Curso: 2025/2026 Q1

Índice

1. Descripción del proyecto	3
1.1. Introducción y contexto	3
1.2. Objetivos del proyecto	3
1.3. Descripción del conjunto de datos	3
2. Estudios previos sobre el conjunto de datos	3
2.1. El modelo de referencia del autor (Marcel Biezunski)	4
2.2. Originalidad de nuestra propuesta	4
3. Exploración de los datos	4
3.1. Limpieza y reestructuración del Dataset	4
3.1.1. Variable objetivo	4
3.1.2. Tratamiento de valores faltantes y escalado	4
3.2. Extracción y selección de características	5
3.3. Agrupamiento y visualización	5
3.3.1. PCA	5
3.3.2. t-SNE	6
3.3.3. Clustering	6
4. Protocolo de remuestreo	8
4.1. División Train/Test	8
4.2. Validación de la distribución de clases	8
4.3. Selección de hiperparámetros	8
5. Resultados con métodos lineales	9
5.1. Resultados obtenidos	9
5.2. Análisis de los resultados	9
6. Resultados con métodos no lineales	10
6.1. Resultados obtenidos	10
6.2. Análisis de los resultados	11
6.2.1. Random Forest	11
6.2.2. Gradient Boosting	11
6.2.3. SVM con Kernel RBF	11
6.2.4. Importancia de las variables	11
7. Comparativa y análisis sobre rendimiento	12
7.1. Tabla resumen de resultados	12
7.2. Análisis del rendimiento	12
8. Modelo final	12
8.1. Justificación de la elección	12
8.2. Estimación del rendimiento	13
9. Análisis de interpretabilidad de los modelos	13
9.1. Importancia de los atributos	13
9.2. Análisis de Casos Reales (Test 2024-2025)	14
10. Conclusiones	14
10.1. Autoevaluación: éxitos, fracasos y dudas	14
10.2. Conclusiones científicas y personales	15
11. Referencias	15

1. Descripción del proyecto

1.1. Introducción y contexto

El análisis de datos en el deporte y concretamente en el fútbol, se ha convertido en una herramienta fundamental tanto para clubes como para analistas deportivos.

Este proyecto se centra en la Liga española de fútbol, analizando datos históricos de partidos que van desde la temporada 2019/2020 hasta el inicio de la actual temporada 2025/2026, más en concreto hasta la jornada 7 de esta.

1.2. Objetivos del proyecto

El objetivo principal es desarrollar un modelo de aprendizaje automático capaz de predecir el rango de goles totales que se marcarán en un partido futuro, basándose exclusivamente en información previa al encuentro.

Para lograrlo, se han definido los siguientes objetivos:

1. **Feature Engineering:** transformar los datos crudos de partidos en métricas predictivas útiles. Ya sea el estado de forma actual (últimos 5 partidos), como el historial de enfrentamientos directos H2H (head-to-head) y el rendimiento acumulado de la temporada.
2. **Definición del problema de clasificación:** transformar la variable objetivo continua, que es el total de goles, en una variable categórica de 3 clases que representa la naturaleza del partido:
 - **Clase 0 (partido cerrado):** 0 o 1 goles.
 - **Clase 1 (partido estándar):** 2 o 3 goles.
 - **Clase 2 (partido abierto):** 4 o más goles.

1.3. Descripción del conjunto de datos

El conjunto de datos seleccionado para este estudio es el LaLiga Matches Dataset 2019-2025 (FBref), disponible en el repositorio público de Kaggle [1]. Este dataset recopila información detallada de todos los partidos disputados en la primera división española desde el inicio de la temporada 2019-20 hasta las primeras jornadas de la temporada 2025-26.

Aunque el archivo original presenta un desglose por equipo, para este proyecto se ha generado un dataset final estructurado por partido único, consolidando la información de local y visitante en una misma fila. El volumen total de datos asciende a aproximadamente 2.350 encuentros.

El conjunto de datos final incluye dos tipos de información:

1. **Datos del Partido (Originales):** Identificadores (fecha, equipos, árbitro) y métricas de juego (goles reales, resultado).
2. **Variables Predictivas (Añadidas):** Métricas de contexto histórico calculadas específicamente para este estudio, que incluyen:
 - Estado de forma: Medias móviles de los últimos 5 partidos (Last-5).
 - Acumulados: Totales de goles y puntos en la temporada vigente.
 - Historial: Estadísticas de enfrentamientos directos previos (Head-to-Head).
 - Descanso: Días desde el último partido.

2. Estudios previos sobre el conjunto de datos

El análisis del fútbol y la predicción de resultados deportivos es un campo de investigación que ha experimentado una evolución significativa en las últimas décadas. Dado que el conjunto de datos

es un recurso abierto y en constante actualización, todos los estudios asociados se concentran en el repositorio de código de Kaggle.

Tras realizar una revisión exhaustiva del repositorio, se han identificado una serie de modelos predictivos públicos desarrollados con estos datos específicos. Todos estos estudios siguen el mismo patrón, todos se centran exclusivamente en la predicción del resultado del partido.

2.1. El modelo de referencia del autor (Marcel Biezunski)

Entre los estudios identificados, destaca el desarrollado por el propio creador del dataset, Marcel Biezunski [2], que establece el punto de referencia para este conjunto de datos. Implementa un modelo de clasificación basado en Random Forest. Su enfoque se basa en el cálculo de medias móviles con una ventana temporal de 3 partidos.

Para predecir el ganador, utiliza métricas técnicas muy específicas del juego, como la distancia media de los disparos, el porcentaje de tiros a puerta o los toques en el área rival. Este enfoque logra capturar la tendencia general de los equipos, pero se limita a predecir el signo del encuentro, alcanzando precisiones de alrededor 50 % y 60 %, un umbral estándar en la predicción de resultados de fútbol debido a la alta aleatoriedad del deporte.

2.2. Originalidad de nuestra propuesta

El análisis de los 6 modelos existentes confirma que ninguno de ellos explota lo que nosotros queremos estudiar, ninguno predice el volumen de goles. Pasamos de una clasificación de signo (1/X/2) a una clasificación del número de goles (0-1/2-3/4+ goles).

Además, estos estudios suelen depender de métricas de juego más aleatorias como los tiros o la posesión, nosotros dependemos de datos más fiables y realistas, como el estado de forma y el historial directo, añadiendo variables totalmente diferentes a la de los estudios. Muchos de esos estudios son más descriptivos y no hacen una predicción pre-partido como hacemos nosotros, ya que suelen utilizar estadísticas como las que he mencionado previamente.

3. Exploración de los datos

A continuación, se detalla la metodología seguida para transformar los datos brutos de partidos LaLiga (2019-2025) en un conjunto de datos apto para el entrenamiento de modelos de clasificación.

3.1. Limpieza y reestructuración del Dataset

Antes de empezar a aplicar diferentes modelos y ver el rendimiento hemos realizado una limpieza de datos y una reestructuración del dataset, con el objetivo de simplificar el tratamiento de datos.

El conjunto de datos original contenía dos filas por partido, una desde la perspectiva del equipo local y otra del visitante, por eso el primer paso ha sido reestructurar el dataset para obtener una única fila por encuentro que contuviera la información conjunta de ambos equipos.

3.1.1. Variable objetivo

En un principio planteamos un problema de regresión sobre los goles, sin embargo, después de analizar la distribución y la dificultad de predecir el resultado exacto, optamos por realizar un problema de clasificación con tres clases mencionadas anteriormente. Para ello no hemos basado en la distribución de frecuencias de goles de LaLiga.

3.1.2. Tratamiento de valores faltantes y escalado

Detectamos valores nulos en las métricas de racha durante las primeras jornadas de cada temporada, esto se debe a que no existen partidos previos. Estos valores se imputaron utilizando medias globales o ceros según el contexto de la variable, asegurando no perder datos de inicio de temporada.

Finalmente, para evitar que variables con magnitudes grandes, como días de descanso o histórico de goles, dominaran sobre las pequeñas, aplicamos una estandarización a todas las variables numéricas.

3.2. Extracción y selección de características

Para poder capturar la evolución temporal y contextual del fútbol, hemos generado variables predictivas.

- **Métricas de racha:** Hemos calculado la media de los últimos cinco partidos para cada equipo, de esta forma el modelo puede tener en cuenta el estado de forma y la fatiga actual. Entre estas nuevas variables se encuentran: `home_gf5`, `home_pts5`, `home_ga5`, `away_ga5`, etc.
- **Métricas de Temporada:** Se implementa medias acumuladas para capturar el nivel del equipo en la temporada actual. De esta forma, se puede distinguir entre una mala racha y un mal equipo.
- **Histórico de enfrentamientos:** Hemos creado variables específicas para medir la rivalidad histórica entre dos equipos, como el promedio de goles en sus enfrentamientos previos (`h2h_goals`).

Para hacer la selección de variables predictivas, eliminamos todas las variables conocidas una vez finalizado el partido, como goles actuales, resultado, estadísticas del juego en curso, etc. De esta forma conservábamos únicamente la información disponible antes del pitido inicial.

3.3. Agrupamiento y visualización

Para comprender mejor la estructura del espacio de características antes del modelado, hemos aplicado técnicas de reducción de dimensionalidad y clustering no supervisado.

3.3.1. PCA




Figura 1: Proyección en 2 dimensiones de los partidos (PCA)

Se ha proyectado las variables escaladas a 2 dimensiones. Podemos observar que las primeras dos componentes explican el 51.1 % de la varianza del dataset, además revela una superposición significativa entre las tres categorías de goles. Esto confirma que el problema no es linealmente separable y justifica la necesidad de probar modelos no lineales en etapas posteriores. Indica también que las estadísticas pre-partido son muy similares tanto en partidos que terminan 0-0 como en los que terminan 4-3.

3.3.2. t-SNE

Para complementar el análisis de PCA, se ha aplicado la técnica t-SNE, con el objetivo de explorar la estructura local de los datos mediante una proyección no lineal.




Figura 2: Agrupamiento no lineal de partidos (t-SNE)

A diferencia de PCA, t-SNE intenta agrupar instancias similares. No obstante, el gráfico resultante muestra una nube dispersa y homogénea donde las tres clases de la variable objetivo aparecen completamente entremezcladas sin formar clusters definidos. Esta ausencia de separación sugiere que la diferencia entre un partido de 1 gol y uno de 3 goles no depende de una o dos variables dominantes, sino de interacciones complejas y sutiles entre múltiples predictores.

3.3.3. Clustering

Hemos realizado un agrupamiento con el algoritmo K-Means. El objetivo de este apartado consiste en comprender la estructura latente de los datos para identificar patrones de juego o tipos de partidos que no son evidentes a simple vista, y además, se pretende utilizar esta estructura para realizar una Feature Engineering. La asignación de clusters y las distancias a los mismos se utilizarán posteriormente como nuevas variables predictivas para enriquecer el entrenamiento.




Figura 3: Selección de K óptimo: Elbow vs Silhouette

Para determinar el número óptimo de grupos (k), evaluamos dos métricas, la Inercia y el Coeficiente de Silhouette. Como se puede observar en la gráfica, el coeficiente de Silhouette alcanza su máximo global en $k = 2$, lo que sugiere que la separación matemática más nítida es binaria. Sin embargo, como des del punto de vista del futbol una partición binaria puede resultar simple, optamos por

seleccionar $k = 3$ basándonos en el comportamiento del Elbow plot. De esta forma, permitimos al modelo distinguir entre tres estados tácticos: defensivo/cerrado, transición/estándar y ofensivo/roto.




Figura 4: Clusters K-Means

Aunque el resultado exacto de un partido es ruidoso, los equipos poseen estilos de juego identificables. A diferencia de la proyección anterior, aquí podemos observar una alta coherencia espacial. Vemos que los tres clusters ocupan regiones del espacio bien delimitadas y con poca superposición. Esto confirma que las variables de entrada contienen patrones que permiten diferenciar tres tipos claros de comportamientos.

A partir de esta información, hemos decidido crear nuevas variables basadas en la distancia a centroides y el Cluster id. Al ser grupos matemáticamente distintos, estas nuevas variables aportarán al modelo supervisado información clara.

Una vez asignados los clusters, hemos realizado un análisis de perfilado para dar significado a cada grupo. Para ello se calculó el promedio de las variables originales dentro de cada clúster.




Figura 5: Mapa de Calor: ¿Qué define a cada Cluster?

En este mapa de colores, los valores representan desviaciones estándar respecto a la media de la liga. Se revelan tres perfiles de comportamiento que validan la segmentación y nos permite definir los clusters de la siguiente manera:

- **Cluster 0, juego defensivo:** agrupa a equipos con dificultades ofensivas. Son encuentros con tendencia a bajos marcadores.
- **Cluster 1, defensa vulnerable:** contiene un valor muy alto en Goles en Contra, manteniendo una producción ofensiva y puntuación cercanas a la media.
- **Cluster 2, Dominio ofensivo:** Corresponde a los equipos dominantes de la liga. Poseen una alta capacidad goleadora que suele dictar el ritmo del partido.

Esto nos confirma que el algoritmo K-means ha logrado separar los partidos no por azar, sino basándose en calidad y el estilo defensivo/ofensivo de los equipos. Añadiremos esta información al modelo supervisado con tal de mejorar la precisión en los casos límite.

Finalmente, para validar la coherencia del agrupamiento, hemos visualizado los resultados de K-Means ($k = 3$) sobre las dos primeras componentes principales (PC1 y PC2).




Figura 6: Visualización de clusters usando PCA

Podemos ver que la distribución tiene forma de V donde los tres clusters ocupan regiones distintas pero contiguas. Podemos identificar claramente puntos aislados en el cuadrante superior derecho que se alejan de la nube principal. Estos puntos representan partidos atípicos.

4. Protocolo de remuestreo

Para simular un entorno de producción real y evitar fugas de información futura, descartamos el particionamiento aleatorio, optando por una división temporal.

4.1. División Train/Test

Establecemos una frontera cronológica para respetar la evolución cronológica de los datos.

- **Train (2019-2023):** ≈ 1900 partidos (81 %). Permite al modelo aprender la evolución de los equipos durante 4 años completos.
- **Test (2024-2025):** ≈ 450 partidos (19 %). Reservados exclusivamente para evaluar el rendimiento en datos futuros no vistos.

4.2. Validación de la distribución de clases

Hemos verificado la estratificación de la variable objetivo y mantiene una consistencia en la proporción entre el train y test. La clase 'Normal' (2-3 goles) se mantiene como la moda en ambos conjuntos. Además, la jerarquía de frecuencias se preserva intacta (Clase 1 > Clase 0 > Clase 2) y las desviaciones entre conjuntos no superan el 3.1 % en ninguna categoría.

4.3. Selección de hiperparámetros

En el modelo de random forest, restringimos la profundidad máxima y aumentaron las muestras mínimas por hoja. De esta forma el modelo aprende patrones globales de racha y estado de forma, impidiendo la memorización de equipos o partidos específicos.

Para evitar que el modelo ignorase las clases minoritarias, partidos cerrados o abiertos, hemos priorizado las configuraciones que obtenían menor diferencia entre train i test.

5. Resultados con métodos lineales

Se nos pide que hagamos 3 experimentos lineales o cuadráticos. Hemos escogido aplicar Regresión Logística, SVM lineal y K Nearest Neighbors. Cada uno de ellos ha sido aplicado con sus mejores hiperparámetros.

5.1. Resultados obtenidos




Figura 7: Matrices de Confusión: Regresión Logística, SVM Lineal y KNN

5.2. Análisis de los resultados

Se presentan los resultados con los tres algoritmos seleccionados. Como ya intuimos previamente, el rendimiento de los modelos lineales frente a un conjunto de datos con mucho ruido y de difícil predicción ha sido no muy bueno.

Tanto la Regresión Logística como el SVM lineal muestran un desempeño muy similar, con un F1-Macro (en validación cruzada temporal) en torno a 0.337 y 0.335 respectivamente. Vemos que estos modelos logran identificar mejor las clases minoritarias (Cerrado y Abierto) que el KNN. Se puede observar en la Regresión Logística que el recall de la clase Abierto es de 0.43, lo que nos dice que es capaz de identificar el 43 % de las goleadas, un dato meritorio, aunque a costa de una precisión baja (0.31).

Por otro lado, el modelo de K-Nearest Neighbors (KNN) presenta una discrepancia notable. Aunque muestra un Accuracy alto en el conjunto de entrenamiento (0.534), su F1-Macro en validación cae a 0.326, el más bajo de los tres. Al observar el informe, vemos que el KNN se especializa agresivamente en la clase mayoritaria (Normal), con un recall del 77 %, pero falla estrepitosamente en la detección de goleadas (clase Abierto), donde su recall se desploma al 22 %, casi la mitad que los modelos lineales.

En conclusión, los resultados demuestran que no existe una separación lineal clara entre las variables de estado de forma y la cantidad de goles. Este rendimiento limitado, donde el modelo más equilibrado apenas supera el 39 % de acierto global, justifica la necesidad de explorar métodos no lineales y de ensemble.

6. Resultados con métodos no lineales

Tras la limitación observada en los modelos lineales, se han explorado algoritmos capaces de capturar relaciones más complejas y que tienen la capacidad de darle un cierto peso a las variables que más utiliza. Para ello hemos escogido los tres siguientes métodos: Random Forest, Gradient Boosting y SVM con Kernel RBF.

6.1. Resultados obtenidos




Figura 8: Matrices de Confusión: Random Forest, Gradient Boosting y SVM RBF




Figura 9: Importancia de las variables: Random Forest y Gradient Boosting

6.2. Análisis de los resultados

6.2.1. Random Forest

Este primer método obtiene una Accuracy de 0.889 y un F1-Macro de 0.348. Random Forest muestra un comportamiento destacado. La profundidad limitada a 10 permite un ajuste mucho más preciso, buscando reglas más específicas. La clase normal funciona muy bien, con un recall de 0.92, lo que hace que este método sea muy estable dado que es la clase mayoritaria.

Además, lo más interesante de esta configuración es que al ajustar la profundidad, ha mejorado notablemente la sensibilidad en los extremos. Lejos de sufrir con las clases minoritarias, ha logrado subir el recall al 87% para partidos cerrados y al 85% para partidos abiertos (goleadas), lo cual es una mejora sustancial respecto a configuraciones previas.

6.2.2. Gradient Boosting

Este método obtiene un Accuracy de 0.749 y un F1-Macro de 0.337. Este método se especializa de manera contundente en la clase Normal, alcanzando un recall del 98% (el máximo de los experimentos), pero a la hora de detectar los partidos de muchos goles le cuesta más, detectando un 52%.

6.2.3. SVM con Kernel RBF

Este último método de modelos no lineales obtiene un accuracy 0.463 y un F1-Macro 0.355. Este es el modelo más equilibrado que no se centra tanto en detectar la clase normal. Su f1-score en las clases minoritarias (Cerrado y Abierto) es superior al de los otros modelos (0.38 y 0.40 respectivamente).

6.2.4. Importancia de las variables

La variable `h2h_goals` (promedio de goles en los enfrentamientos entre los dos equipos) tiene mucha importancia en ambos modelos, destacándose en el Gradient Boosting. Esto sugiere que los estilos de juego entre dos equipos son muy relevantes. Si un Rayo - Getafe suele ser cerrado, el modelo aprende que lo seguirá siendo, independientemente de cómo lleguen a la jornada.

Por otro lado, en el Random Forest vemos que las variables más determinantes son las estadísticas acumuladas del equipo local (goles en contra y goles a favor totales). Esto es muy interesante, ya que el modelo nos está diciendo que la solidez defensiva (`home_ga_total`) y la potencia ofensiva (`home_gf_total`) del anfitrión son los mejores datos para saber si el partido se abrirá o no, pesando más que la situación del visitante.

Otras variables que tienen mucho en cuenta ambos modelos son las relacionadas con la clasificación general de toda la temporada, destacando especialmente los puntos totales (`home_pts_total` y `away_pts_total`). Esto nos confirma que la regularidad de los equipos y su posición en la tabla, pesan más a la hora de predecir el tipo de partido que datos como la racha actual.

Por lo contrario, variables que a priori parecían importantes, como los días de descanso o sobre todo las estadísticas de los últimos 5 partidos (la racha actual) y el descanso de los equipos antes de un partido, son las que menos tiene en cuenta.

7. Comparativa y análisis sobre rendimiento

Tras completar todos los experimentos, vamos a ver la comparación directa de tanto los métodos lineales como los no lineales. El objetivo es seleccionar el modelo que ofrezca el mejor equilibrio.

7.1. Tabla resumen de resultados

La siguiente tabla muestra el rendimiento óptimo alcanzado por cada algoritmo tras el ajuste de hiperparámetros:

Tipo Modelo	Algoritmo	Accuracy	F1-Macro	Comportamiento Principal
Lineal	Regresión Logística	39.1 %	0.337	Rendimiento modesto pero estable.
Lineal	SVM Lineal	39.3 %	0.335	Similar a la Regresión Logística.
Distancia	KNN	53.4 %	0.326	Alto error de generalización.
Ensemble	Random Forest	88.9 %	0.348	Sobreajuste alto en train, pero F1 compet
Ensemble	Gradient Boosting	74.9 %	0.337	Muy sesgado a la clase Normal (Recall 98
No Lineal	SVM (Kernel RBF)	46.3 %	0.355	Mejor F1-Macro y menor sobreajuste.

Cuadro 1: Comparativa de resultados

7.2. Análisis del rendimiento

El análisis del rendimiento revela tres patrones fundamentales que definen la naturaleza del problema:

1. **La limitación de la linealidad:** los modelos lineales (Regresión Logística y SVM Lineal) se estancan en un rendimiento cercano al 39 %. Esto confirma la hipótesis inicial: la relación entre las métricas de estado de forma y la intensidad goleadora de un partido no es lineal. Los árboles de decisión y el SVM no lineal capturan mejor las interacciones complejas.
2. **Accuracy Paradox y sobreajuste:** el modelo Gradient Boosting ilustra perfectamente este fenómeno. Ha logrado un acierto masivo en entrenamiento (74,9 %), pero paradójicamente su capacidad de generalización es limitada (F1-Macro de 0.337). Este método tiene una estrategia conservadora y sesgada: aprende a predecir casi siempre la clase Normal (con un recall del 98 %), maximizando la estadística de acierto pero fallando al identificar los partidos fuera de lo común en validación.

8. Modelo final

8.1. Justificación de la elección

Tras evaluar todos los candidatos, creemos que el mejor modelo es el de Random Forest. A pesar de que los otros modelos no lineales también tuvieron buenos resultados, Random Forest es el que ofrece la mejor combinación entre los siguientes factores:

1. **Equilibrio:** mantiene un balance aceptable entre detectar goleadas y acertar el resultado general.
2. **Interpretabilidad:** a diferencia del SVM, el Random Forest nos permite medir la importancia de cada variable, lo cual es vital para validar todo el sentido futbolístico para este modelo.
3. **Estabilidad:** al basarse en el promedio de múltiples árboles, es menos propenso al sobreajuste en datos futuros con mucho ruido.

8.2. Estimación del rendimiento

Para verificar la capacidad real del modelo, realizamos una evaluación final sobre el conjunto de test, compuesto por la temporada 2024 completa y las primeras 7 jornadas de la temporada 2025. Son datos que el modelo nunca vio durante el entrenamiento. Al aplicar Random Forest sobre este conjunto, se obtuvieron los siguientes resultados:

- **Accuracy Global:** El modelo alcanzó una exactitud del 38.22 % en el conjunto de prueba. Observamos una gran caída respecto al 88.9 % obtenido en train. Este descenso evidencia un claro sobreajuste a los datos históricos, donde el modelo memorizó patrones específicos del pasado (2019-2023) que no se han replicado exactamente en el futuro.
- **Análisis por Clases:**
 - **Clase Normal (2-3 goles):** Es la categoría donde el modelo se comporta mejor, con una precisión del 51 % y un recall del 52 %.
 - **Clase Cerrado y Abierto:** El rendimiento desciende en los extremos. Para los partidos cerrados (0-1 goles) y abiertos (+4 goles), el modelo presenta un recall bajo (23 % y 26 % respectivamente). Esto indica que, aunque el modelo detecta bien la tendencia general de la liga, le cuesta anticipar los partidos que se salen de la norma.

Parte del problema seguramente venga dado porque tener 7 jornadas de la temporada 2025 puede ser conflictivo. Las variables acumulativas claves (como `home_pts_total` o `home_gf_total`) tienen valores muy bajos al inicio del campeonato y no reflejan el nivel real de los equipos, confundiendo a un modelo que aprendió mayoritariamente de temporadas completas.

En conclusión, la evaluación confirma que el fútbol mantiene un componente aleatorio alto. Aunque se supera el azar puro (33 %), la brecha entre train y test indica que las estadísticas previas son indicadores útiles de tendencia, pero no determinantes absolutos del marcador exacto.

9. Análisis de interpretabilidad de los modelos

Para este apartado, hemos mirado detalladamente el modelo final (Random Forest) para entender su lógica interna y compararla con una visión más simple como la de los modelos lineales. Obteniendo la siguiente tabla:

Variable	Peso_Lineal	Importancia_Arbol
home_ga_total	0.367602	1.000000
home_gf_total	1.000000	0.927118
home_pts_total	0.779696	0.907286
h2h-goals	0.388434	0.902789
away_pts_total	0.676578	0.873494
pts5_diff	0.242026	0.852080
away_ga_total	0.559310	0.792213
away_gf_total	0.760521	0.780050
rest_diff	0.381826	0.749799
home_gf5	0.238474	0.712977

Cuadro 2: Tabla comparativa de importancia de variables

9.1. Importancia de los atributos

La tabla comparativa entre los pesos del modelo lineal (Regresión Logística) y la importancia del modelo no lineal (Random Forest) revela una diferencia fundamental en la toma de decisiones:

1. **Solidez defensiva local:** la variable más relevante es la cantidad de goles que ha encajado el equipo local en la temporada (`home_ga_total`). El modelo ha aprendido que si el anfitrión defiende mal, el partido tiende a romperse. El modelo lineal infravalora esto (peso 0.36), centrándose solo en el ataque, pero el árbol de decisión entiende que la defensa condiciona el marcador.
2. **Potencia ofensiva local:** en segundo lugar, aparece la capacidad goleadora del local (`home_gf_total`) aparece en ambos modelos. Esto confirma que en La Liga, el equipo de casa suele llevar la iniciativa.
3. **Calidad Estructural y H2H:** los puntos del local y el historial directo (`home_pts_total` y `h2h_goals`) también son muy relevantes en el Random Forest. El modelo combina los enfrentamientos históricos como los puntos totales de la temporada del equipo local, en cambio vemos que el modelo lineal no los tiene tan en cuenta.

9.2. Análisis de Casos Reales (Test 2024-2025)

Para validar la lógica interna del Random Forest, hemos extraído dos ejemplos concretos del conjunto de test que ilustran cómo el modelo procesa la información conflictiva:

1. **Gestión de señales contradictorias:** era un caso donde el historial directo de goles era muy alto ($h2h_goals = 3,5$), lo que sugería una goleada. Sin embargo, el equipo local llegaba con pocos goles en la temporada ($home_gf_total = 16,0$), lo que sugiere un partido cerrado. Ante estas señales opuestas el modelo ha sabido hacer un balance entre estos dos datos, prediciendo de forma correcta los goles de ese partido, clasificándolo a la clase Normal. Esto demuestra que el algoritmo pondera los múltiples factores y no se deja llevar solo por una sola variable.
2. **Ejemplo con historial vacío:** este es un caso extremo donde el modelo se encontró con un caso extremo, donde el promedio de goles en los enfrentamientos entre ambos equipos era de 0. De forma lógica el modelo predijo que este partido iría a la clase Cerrado (0 o 1 goles). Sin embargo, el partido terminó siendo una goleada. Este es un error muy típico que nos demuestra lo aleatorio que puede ser el fútbol.

10. Conclusiones

10.1. Autoevaluación: éxitos, fracasos y dudas

El proyecto ha cumplido su objetivo principal, que era el de transformar un problema altamente aleatorio como es el fútbol, en un sistema predictivo estructurado.

Éxitos

El mayor triunfo del proyecto ha sido la capacidad de implementar Ingeniería de Características. Hemos conseguido demostrar que variables sintéticas como la fragilidad defensiva o el historial directo (H2H) tienen una correlación real con los goles, superando a las métricas iniciales.

Limitaciones del planteamiento inicial

La principal limitación encontrada fue la dificultad de clasificar los partidos en tres categorías. Como hemos visto en los resultados del modelo final, el solapamiento entre las clases provocó un estancamiento del Accuracy en torno al 38 %. Esto se debe a la aleatoriedad del fútbol, en muchas ocasiones la diferencia entre un partido de 1 gol y uno de 2 goles es causa de una jugada aislada en el último minuto, lo que introduce un nivel de ruido que las variables pre-partido no pueden filtrar.

Extensión experimental

Para comprobar la hipótesis de que las variables sí contenían información predictiva, decidimos realizar una extensión del estudio simplificando el problema a una clasificación binaria estándar en la industria de las apuestas: Menos de 2.5 goles vs Más de 2.5 goles.

Al reentrenar el modelo Random Forest con esta nueva variable objetivo, los resultados mejoraron drásticamente, confirmando nuestra hipótesis.

- **Mejora del Rendimiento:** El modelo pasó de un acierto del 38 % a un Accuracy en Test del 77.2 %, demostrando que el algoritmo es altamente eficaz para distinguir entre partidos 'cerrados' y 'abiertos' cuando se elimina la ambigüedad de la clase intermedia.
- **Fiabilidad Defensiva (Under 2.5):** El modelo alcanzó un Recall del 90 % para la clase de pocos goles. Esto nos indica que, cuando predice que habrá pocos goles, acierta la gran mayoría de las veces.
- **Precisión Ofensiva (Over 2.5):** Para los partidos de muchos goles, el modelo mostró una Precisión del 86 %. Cuando pronosticar una goleada, tiene una probabilidad muy alta de estar en lo cierto.

Esta extensión nos permite concluir que las limitaciones no se trataba tanto de la calidad de los datos, sino en la definición del problema.

10.2. Conclusiones científicas y personales

Hemos demostrado que, con datos pre-partido, es viable modelar la si un encuentro será cerrado o abierto con una alta precisión, pero resulta muy difícil clasificar el marcador debido a la varianza estocástica del deporte.

A nivel personal, la principal lección ha sido comprender que la Ciencia de Datos no es un proceso lineal. Enfrentarnos al bajo rendimiento inicial del modelo de 3 clases nos ha obligado a redefinir el problema de negocio en lugar de insistir en una vía agotada. Este proyecto nos ha enseñado que un buen científico de datos no es solo quien ajusta hiperparámetros, sino quien sabe adaptar las preguntas a la realidad que dictan los datos.

Dudas pendientes y posibles extensiones

Nos queda la incertidumbre sobre la limitación de los datos pre-partido. Nos preguntamos si hubiera mejorado el modelo de 3 clases si hubiéramos tenido acceso a datos como las alineaciones confirmadas o las bajas por lesión o si tuviéramos también acceso a datos de los equipos en otras competiciones, ya que hay equipos que juegan competiciones europeas y por tanto el desgaste no es el mismo.

Para superar la barrera del 77 % y volver a abordar el problema de las 3 clases con garantías, hemos pensado en futuros enfoques de estudios.

1. **Variables intra-partido simuladas:** Incorporar datos de alineaciones confirmadas o bajas de última hora (lesiones de jugadores clave), que no estaban disponibles en este dataset.
2. **Análisis de Texto:** Utilizar técnicas de NLP sobre las crónicas previas de los partidos para captar la motivación de los equipos, como por ejemplo la necesidad de ganar para no descender.

11. Referencias

- [1] Biezunski, M. (2025). *LaLiga Matches Dataset (2019-2025, FBref)* [Conjunto de datos]. Kaggle. Disponible en: <https://www.kaggle.com/datasets/marcelbiezunski/laliga-matches-dataset-2019-2025-fbref>
- [2] Reda Gamal, M. (2025). *LaLiga Matches Dataset (2019-2025, FBref) - Match Outcome Prediction* [Código de análisis]. Kaggle. Disponible en: <https://www.kaggle.com/code/mahmoudredagmail/laliga-matches-dataset-2019-2025-fbref>